

Identificação de Motor CC por Filtros Adaptativos FIR: Replicação Computacional com LMS e NLMS

Alberi Medeiros Santos

Departamento de Engenharia Elétrica/
Programa de Pós-Graduação em Engenharia Elétrica, UFCG
alberi.santos@ee.ufcg.edu.br

Edson Porto da Silva

Departamento de Engenharia Elétrica/
Curso de Pós-Graduação em Engenharia Elétrica, UFCG
edson.silva@dee.ufcg.edu.br

Resumo

Este trabalho apresenta uma replicação computacional, em ambiente simulado, da metodologia de identificação de um motor de corrente contínua por filtros adaptativos, inspirada no artigo *Adaptive Filters for DC Motor Identification: A Case Study*. O escopo foi restringido aos algoritmos *Least Mean Squares* (LMS) e *Normalized Least Mean Squares* (NLMS), com o filtro de Wiener utilizado como referência ótima em lote. Os dados de entrada e saída foram gerados a partir de uma planta simulada de motor CC em espaço de estados, amostrada com $T_s = 1$ ms e excitada por uma sequência binária pseudoaleatória. A identificação foi formulada como um problema FIR com 55 coeficientes, valor compatível com a resposta ao impulso estimada da planta. Os algoritmos foram comparados por erro quadrático médio (MSE), comportamento de convergência e tempo de processamento com e sem downsampling. Os resultados indicam que LMS e NLMS aproximaram a dinâmica dominante do motor simulado, com MSE próximo ao da solução de Wiener, sendo o LMS o método de menor custo computacional na implementação avaliada.

Palavras-chave: filtros adaptativos; identificação de sistemas; motor CC; LMS; NLMS; filtro de Wiener; FIR.

1 Introdução

A identificação de sistemas dinâmicos consiste em obter um modelo matemático capaz de representar a relação entre entrada e saída de um processo. Em sistemas eletromecânicos, como motores de corrente contínua (CC), essa identificação é útil para modelagem, simulação, controle e diagnóstico.

O artigo de referência [1] investiga o uso de filtros adaptativos para a identificação de um motor CC a partir de dados medidos, comparando algoritmos como *Least Mean Squares* (LMS), *Normalized Least Mean Squares* (NLMS), *Recursive Least Squares* (RLS) e *Affine Projection* (AP). Neste projeto, a proposta foi reproduzir a lógica metodológica do artigo em um ambiente computacional controlado, restringindo o escopo aos algoritmos LMS e NLMS e utilizando a abordagem teórica traba-

lhada na disciplina de Processamento Adaptativo de Sinais [2, 3, 4].

A motivação principal é relacionar o problema aplicado do artigo com conceitos centrais da disciplina, como filtragem FIR, matriz de autocorrelação, vetor de correlação cruzada, solução de Wiener, erro quadrático médio e adaptação iterativa dos coeficientes. Dessa forma, o estudo não busca reproduzir numericamente os resultados experimentais do artigo, mas sim aplicar sua metodologia em uma planta simulada, permitindo avaliar o comportamento dos algoritmos adaptativos em condições controladas. O fluxo geral adotado no projeto é apresentado na Figura 1.




Figura 1: Diagrama geral da metodologia adotada.

O objetivo central deste trabalho é implementar uma replicação computacional da metodologia de identificação FIR de um motor CC usando os algoritmos LMS e NLMS. Especificamente, busca-se simular uma planta discreta de motor CC, gerar dados de entrada e saída por meio de uma excitação pseudoaleatória do tipo PRBS/SPAB, justificar o uso de um modelo FIR com 55 coeficientes, obter uma solução de Wiener como referência ótima em lote, implementar e avaliar os algoritmos adaptativos e comparar os métodos por erro quadrático médio, *Mean Squared Error* (MSE), comportamento de convergência e tempo de processamento.

O restante deste artigo está organizado da seguinte forma. A Seção 2 apresenta os principais conceitos teóricos utilizados, incluindo identificação FIR, filtro de Wiener, LMS e NLMS. A Seção 3 descreve a planta simulada, a geração dos dados, a escolha do número de coeficientes e os critérios de avaliação. A Seção 4 apresenta os resultados obtidos, incluindo as compara-

ções de erro, convergência e tempo de processamento. Por fim, a Seção 5 apresenta as conclusões, limitações e possibilidades de continuidade do trabalho.

2 Fundamentação Teórica

Filtros adaptativos são estruturas cujos coeficientes são ajustados iterativamente com o objetivo de minimizar uma função custo, usualmente associada ao erro quadrático médio [5, 6, 3].

2.1 Identificação FIR

A identificação foi formulada como um problema de filtragem FIR. O modelo estimado calcula a saída $\hat{d}[k]$ a partir da entrada atual e de amostras atrasadas:

$$\hat{d}[k] = \sum_{i=0}^{M-1} h_i x[k-i] \quad (1)$$

ou, de forma vetorial,

$$\hat{d}[k] = \mathbf{h}^T \mathbf{x}[k], \quad (2)$$

em que

$$\mathbf{x}[k] = [x[k], x[k-1], \dots, x[k-M+1]]^T. \quad (3)$$

Neste trabalho, $M = 55$, seguindo a ordem FIR empregada no artigo de referência e validada pela análise da resposta ao impulso da planta simulada.

2.2 Solução de Wiener

A solução de Wiener fornece o vetor ótimo de coeficientes FIR, no sentido de mínimo erro quadrático médio [5, 2]:

$$\mathbf{h}_{opt} = \mathbf{R}_{xx}^{-1} \mathbf{p}_{xd}, \quad (4)$$

em que

$$\mathbf{R}_{xx} = E[\mathbf{x}[k] \mathbf{x}^T[k]] \quad (5)$$

é a matriz de autocorrelação da entrada, e

$$\mathbf{p}_{xd} = E[\mathbf{x}[k] d[k]] \quad (6)$$

é o vetor de correlação cruzada entre a entrada e a saída desejada. Na implementação computacional, essas estatísticas foram estimadas numericamente a partir dos dados de treino.

2.3 Algoritmo LMS

O algoritmo LMS atualiza os coeficientes do filtro a partir do erro instantâneo:

$$e[k] = d[k] - \hat{d}[k]. \quad (7)$$

A regra de atualização implementada foi:

$$\mathbf{h}[k+1] = \mathbf{h}[k] + 2\mu e[k] \mathbf{x}[k], \quad (8)$$

em que μ é o passo de adaptação. Valores maiores de μ aceleram a convergência, mas podem aumentar oscilações em regime permanente ou causar instabilidade.

2.4 Algoritmo NLMS

O NLMS normaliza a atualização pela energia do vetor de entrada, reduzindo a sensibilidade do algoritmo à escala da excitação [6, 4]:

$$\mathbf{h}[k+1] = \mathbf{h}[k] + \frac{\mu e[k] \mathbf{x}[k]}{\gamma + \mathbf{x}^T[k] \mathbf{x}[k]}, \quad (9)$$

em que γ evita divisão por valores muito pequenos. Essa normalização torna o algoritmo menos sensível à escala da entrada.

3 Metodologia

3.1 Modelo Simulado do Motor CC

Foi utilizada uma planta simulada de motor CC em espaço de estados, inspirada na estrutura apresentada no artigo de referência. O vetor de estados contínuo foi definido como

$$\mathbf{x}_c(t) = [i_a(t) \quad \omega_m(t) \quad \theta_m(t)]^T, \quad (10)$$

em que $i_a(t)$ é a corrente de armadura, $\omega_m(t)$ é a velocidade angular e $\theta_m(t)$ é a posição angular. O modelo contínuo adotado foi

$$\dot{\mathbf{x}}_c(t) = \mathbf{A} \mathbf{x}_c(t) + \mathbf{B} u_a(t), \quad y_c(t) = \mathbf{C} \mathbf{x}_c(t) + \mathbf{D} u_a(t), \quad (11)$$

em que $u_a(t)$ é a tensão aplicada à armadura do motor, $y_c(t)$ é a saída contínua do modelo, $\mathbf{A}$ é a matriz dinâmica, $\mathbf{B}$ é a matriz de entrada, $\mathbf{C}$ é a matriz de saída e $\mathbf{D}$ representa o termo de transmissão direta.

As matrizes do modelo contínuo foram definidas como

$$\mathbf{A} = \begin{bmatrix} -\frac{R_a}{L_a} & -\frac{K_e}{L_a} & 0 \\ \frac{K_t}{J_m} & -\frac{B_m}{J_m} & 0 \\ 0 & 1 & 0 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} \frac{1}{L_a} \\ 0 \\ 0 \end{bmatrix}, \quad (12)$$

$$\mathbf{C} = [0 \quad 1 \quad 0], \quad \mathbf{D} = [0]. \quad (13)$$

Nas matrizes acima, R_a e L_a representam, respectivamente, a resistência e a indutância da armadura; K_t é a constante de torque; K_e é a constante de força contraeletromotriz; J_m é o momento de inércia equivalente; e B_m é o coeficiente de atrito viscoso.

A saída do modelo contínuo corresponde à velocidade angular em rad/s. Posteriormente, a saída foi convertida para rotações por minuto por

$$\omega_{rpm}[k] = \omega_{rad/s}[k] \frac{60}{2\pi}. \quad (14)$$

Os parâmetros físicos utilizados na simulação são apresentados na Tabela 1. Esses valores foram adotados como parâmetros nominais de simulação, não como parâmetros identificados do motor real do artigo. A escolha foi feita de modo a produzir uma dinâmica compatível com o período de amostragem e com a ordem FIR utilizada na identificação.

Como os algoritmos de identificação foram implementados em tempo discreto, a planta contínua foi discretizada pelo método do retentor de ordem zero (ZOH), com período de amostragem

Tabela 1: Parâmetros nominais utilizados na planta simulada do motor CC.

Parâmetro	Valor	Unidade
R_a	2,0	Ω
L_a	$1,2 \times 10^{-2}$	H
K_t	$2,0 \times 10^{-2}$	N m/A
K_e	$2,0 \times 10^{-2}$	V s/rad
J_m	$8,1 \times 10^{-5}$	kg m ²
D_m	$4,35 \times 10^{-3}$	N m s

$$T_s = 1 \text{ ms.} \quad (15)$$

Com essa discretização, obtém-se o modelo

$$\mathbf{x}_s[k+1] = \mathbf{A}_d \mathbf{x}_s[k] + \mathbf{B}_d u[k], \quad y[k] = \mathbf{C}_d \mathbf{x}_s[k] + \mathbf{D}_d u[k], \quad (16)$$

em que $\mathbf{x}_s[k]$, $u[k]$ e $y[k]$ representam, respectivamente, o vetor de estados do sistema, a entrada e a saída amostrados no instante discreto k . As matrizes $\mathbf{A}_d$, $\mathbf{B}_d$, $\mathbf{C}_d$ e $\mathbf{D}_d$ são as versões discretas das matrizes do modelo contínuo.

Para o caso ZOH,

$$\mathbf{A}_d = e^{\mathbf{A}T_s}, \quad \mathbf{B}_d = \int_0^{T_s} e^{\mathbf{A}\tau} \mathbf{B} d\tau. \quad (17)$$

A simulação foi iniciada no ponto de operação associado a $u_0 = 10 \text{ V}$, de modo a evitar um transitório de partida não relacionado ao problema de identificação. A velocidade e a corrente de regime foram calculadas por

$$\omega_0 = \frac{u_0}{K_e + \frac{R_a D_m}{K_t}}, \quad i_{a0} = \frac{D_m}{K_t} \omega_0. \quad (18)$$

Assim, a condição inicial adotada foi

$$\mathbf{x}_s[0] = [i_{a0} \quad \omega_0 \quad 0]^T. \quad (19)$$

Após a simulação, adicionou-se ruído gaussiano à saída em rpm:

$$y[k] = \omega_{\text{rpm}}[k] + n[k], \quad n[k] \sim \mathcal{N}(0, \sigma^2), \quad (20)$$

com $\sigma^2 = 0,1 \text{ rpm}^2$. Para essa configuração, a relação sinal-ruído estimada foi de aproximadamente 30,11 dB.

3.2 Sinais de Identificação

A entrada de identificação foi gerada por uma sequência binária pseudoaleatória do tipo PRBS/SPAB. A sequência discreta $x_{\text{PRBS}}[k]$ assume valores em

$$x_{\text{PRBS}}[k] \in \{-1, +1\}. \quad (21)$$

A tensão aplicada ao motor foi definida em torno do ponto de operação u_0 :

$$u[k] = u_0 + \Delta u x_{\text{PRBS}}[k], \quad (22)$$

em que $u[k]$ é a tensão aplicada ao motor no instante k , u_0 é o nível médio da excitação, Δu é a amplitude da

perturbação em torno do ponto de operação e $x_{\text{PRBS}}[k]$ é a sequência binária pseudoaleatória normalizada. No experimento computacional, adotou-se

$$u_0 = 10 \text{ V}, \quad \Delta u = 0,6 \text{ V}. \quad (23)$$

Assim, a entrada alterna entre aproximadamente 9,4 V e 10,6 V. A sequência foi mantida constante por 50 amostras a cada bit da PRBS, o que corresponde a 50 ms, considerando $T_s = 1 \text{ ms}$. Foram simuladas 100000 amostras, equivalentes a 100 s de operação.

Antes da identificação, os níveis médios foram removidos usando apenas o conjunto de treino:

$$\bar{u}_{\text{train}} = \frac{1}{N_{\text{train}}} \sum_{k=0}^{N_{\text{train}}-1} u[k], \quad (24)$$

$$\bar{y}_{\text{train}} = \frac{1}{N_{\text{train}}} \sum_{k=0}^{N_{\text{train}}-1} y[k]. \quad (25)$$

Os sinais usados pelos filtros adaptativos foram então definidos como

$$x[k] = u[k] - \bar{u}_{\text{train}}, \quad (26)$$

$$d[k] = y[k] - \bar{y}_{\text{train}}. \quad (27)$$

Assim, $x[k]$ representa a entrada centralizada usada pelos filtros adaptativos, enquanto $d[k]$ representa a saída desejada centralizada. O uso das médias calculadas apenas no conjunto de treino evita que informações do conjunto de teste sejam usadas no pré-processamento.

Com isso, a identificação passa a representar a dinâmica incremental em torno do ponto de operação:

$$\Delta u[k] \rightarrow \Delta \omega_m[k]. \quad (28)$$

A Figura 2 apresenta um trecho da entrada PRBS/SPAB aplicada ao motor e a saída simulada correspondente.




Figura 2: Entrada PRBS/SPAB aplicada ao motor e saída simulada em rpm.

3.3 Treino, Teste e Comprimento FIR

Os dados foram divididos em 70% para treino e 30% para teste. Considerando 100000 amostras simuladas, foram usadas 70000 amostras para estimação dos coeficientes e 30000 amostras para avaliação.

O comprimento FIR foi definido com base na resposta ao impulso discreta da planta simulada. Para isso, aplicou-se um impulso unitário à entrada da planta discreta. Seja $g[k]$ a resposta ao impulso estimada e N_{imp} o número total de amostras usadas nessa estimação. Neste trabalho, adotou-se $N_{\text{imp}} = 500$. A fração de energia acumulada até a amostra N foi calculada por

$$E_N = \frac{\sum_{k=0}^{N-1} g^2[k]}{\sum_{k=0}^{N_{\text{imp}}-1} g^2[k]}. \quad (29)$$

O menor valor de N tal que $E_N \geq 0,99$ foi

$$N_{99\%} = 52. \quad (30)$$

Como o artigo de referência utiliza 55 coeficientes no modelo FIR, adotou-se

$$M = 55, \quad (31)$$

valor ligeiramente superior ao comprimento necessário para concentrar 99% da energia da resposta ao impulso estimada. A Figura 3 apresenta os 55 primeiros coeficientes da resposta ao impulso da planta simulada.




Figura 3: Resposta ao impulso estimada da planta simulada do motor CC.

3.4 Métricas de Avaliação

A principal métrica de erro adotada neste trabalho foi o erro quadrático médio, MSE. Essa escolha mantém equivalência com o *Average Squared Error* (ASE) utilizado no artigo de referência, pois ambas as métricas correspondem à média do erro quadrático no intervalo de avaliação:

$$\text{MSE} = \frac{1}{L} \sum_{k=0}^{L-1} (d[k] - \hat{d}[k])^2. \quad (32)$$

em que L é o número de amostras avaliadas, $d[k]$ é a saída desejada centralizada e $\hat{d}[k]$ é a saída estimada pelo filtro no mesmo domínio.

Neste trabalho, o MSE foi calculado sobre o conjunto de teste, desconsiderando as primeiras M amostras, necessárias para formar o vetor de entrada do filtro FIR.

Também foram avaliados:

- MSE de treino e teste;
- curvas de convergência em dB;
- evolução dos coeficientes adaptativos;
- tempo médio de processamento com e sem down-sampling.

3.5 Ambiente Computacional e Implementação

A implementação foi desenvolvida em um notebook Jupyter, seguindo o padrão dos notebooks da disciplina de Processamento Adaptativo de Sinais. A simulação e a identificação foram realizadas em Python, utilizando principalmente as bibliotecas NumPy, SciPy, Matplotlib, SymPy e Numba.

A biblioteca NumPy foi utilizada para operações vetoriais e matriciais. A biblioteca SciPy foi empregada na discretização do modelo contínuo, na simulação da planta discreta, na filtragem FIR e no processo de down-sampling. A biblioteca Matplotlib foi utilizada para geração dos gráficos, enquanto SymPy foi usada apenas para exibição simbólica de expressões e resultados intermediários. As implementações dos algoritmos LMS e NLMS foram aceleradas com Numba por meio de compilação *just-in-time*.

Para garantir a reprodutibilidade dos sinais pseudoaleatórios, foram fixadas duas sementes independentes. A geração da sequência PRBS/SPAB utilizou $s_{\text{PRBS}} = 42$, enquanto a geração do ruído gaussiano de medição utilizou $s_{\text{ruído}} = 123$. Dessa forma, tanto a sequência de excitação quanto a realização específica do ruído são reproduzidas a cada execução do notebook. O tempo de processamento dos algoritmos foi medido por meio de execuções repetidas, utilizando a média dos tempos obtidos. No caso com down-sampling, o custo da decimação não foi incluído na medição; foram considerados apenas os tempos de execução dos algoritmos de identificação.

4 Resultados e Discussão

4.1 Solução de Wiener

O filtro de Wiener foi usado como referência ótima em lote. Os resultados obtidos foram:

$$\text{MSE}_{\text{Wiener}, \text{train}} = 0,2502, \quad (33)$$

$$\text{MSE}_{\text{Wiener}, \text{test}} = 0,2494. \quad (34)$$

A proximidade entre os erros de treino e teste indica boa capacidade de generalização para os dados simulados.

4.2 Desempenho do LMS e NLMS

Os algoritmos LMS e NLMS foram treinados sobre os mesmos dados, com $M = 55$. Os parâmetros usados foram:

$$\mu_{\text{LMS}} = 10^{-4}, \quad \mu_{\text{NLMS}} = 0,1, \quad \gamma = 10^{-6}. \quad (35)$$




Figura 4: Comparação entre saída simulada e saída estimada pelo filtro de Wiener.

A Figura 5 apresenta a comparação entre a saída simulada do motor e as saídas estimadas pelos filtros de Wiener, LMS e NLMS no conjunto de teste. Observa-se que as três estimativas acompanham adequadamente os transientes e patamares da velocidade, indicando que o modelo FIR adotado foi capaz de representar a dinâmica dominante da planta simulada.




Figura 5: Comparação das saídas estimadas por Wiener, LMS e NLMS.

Os valores de erro no conjunto de teste foram:

Tabela 2: MSE no conjunto de teste.

Método	MSE teste [rpm ²]
Wiener	0,2494
LMS	0,2683
NLMS	0,2717

O filtro de Wiener apresentou o menor erro, como esperado por ser uma solução ótima em lote. O LMS e o NLMS apresentaram erros ligeiramente superiores, porém próximos ao Wiener. Isso indica que os algoritmos adaptativos conseguiram identificar a dinâmica dominante do motor simulado.

Embora o NLMS seja, em geral, mais robusto a variações de amplitude da entrada por normalizar o passo de adaptação pela energia do vetor de entrada, essa vantagem não se destacou de forma significativa neste experimento. Isso ocorre porque a excitação PRBS/SPAB utilizada possui amplitude aproximadamente constante, fazendo com que a energia do vetor de entrada varie pouco ao longo das iterações. Nessa condição, o comportamento do NLMS tende a se aproximar do LMS, e a diferença de desempenho passa a depender principalmente da escolha dos parâmetros de adaptação. Assim, para a configuração avaliada, LMS e NLMS apresentaram desempenho equivalente, com pequena vantagem numérica para o LMS no conjunto de teste.

4.3 Convergência dos Algoritmos

A Figura 6 apresenta as curvas de convergência dos algoritmos LMS e NLMS. O LMS inicia com erro elevado devido à inicialização nula dos coeficientes e converge progressivamente para a região do MMSE associado ao filtro de Wiener. O NLMS atinge rapidamente essa região devido à normalização do passo de adaptação pela energia do vetor de entrada.




Figura 6: Curvas de convergência dos algoritmos LMS e NLMS.

A análise do passo μ evidenciou o compromisso entre velocidade de convergência e estabilidade. Valores maiores de μ aceleram a redução inicial do erro, mas podem aumentar as oscilações em regime permanente. Valores muito pequenos produzem adaptação lenta.




Figura 7: Influência do passo de adaptação na convergência do LMS.

4.4 Coeficientes Adaptativos

A evolução dos coeficientes adaptativos vista na Figura 8 permite observar o processo de aprendizado dos filtros. No LMS, os primeiros coeficientes apresentam evolução mais suave devido ao passo fixo e pequeno. No NLMS, a adaptação é mais rápida, mas pode apresentar maior oscilação, especialmente para valores mais agressivos de μ_{NLMS} .

4.5 Tempo de Processamento

Os tempos médios de processamento foram avaliados com e sem downsampling. O fator de downsampling utilizado foi 10, reduzindo o conjunto de treino de 70000 para 7000 amostras. O custo do pré-processamento de decimação não foi incluído; foram medidos apenas os tempos de execução dos algoritmos de identificação.




Figura 8: Evolução dos primeiros coeficientes adaptativos dos filtros LMS e NLMS durante o treinamento.

Tabela 3: MSE de teste e tempos de processamento.

Método	MSE teste	Com DS	Sem DS
Wiener	0,2494	0,05649 s	0,43497 s
LMS	0,2683	0,00453 s	0,05575 s
NLMS	0,2717	0,00970 s	0,12367 s

Observa-se que o LMS foi o algoritmo mais rápido nesta implementação, seguido pelo NLMS. O filtro de Wiener apresentou maior custo computacional devido à estimação das estatísticas de segunda ordem e à resolução do problema matricial. O downsampling reduziu significativamente o tempo de processamento em todos os métodos.

Deve-se observar que o MSE apresentado na Tabela 3 corresponde aos modelos treinados sem downsampling. Os tempos com downsampling indicam apenas a redução de custo computacional ao executar os algoritmos em dados decimados. Uma extensão natural é calcular também o MSE dos modelos treinados com downsampling.

4.6 Limitações

A principal limitação deste trabalho é o uso de uma planta simulada, e não dos dados experimentais reais do artigo. Portanto, os valores absolutos de MSE e tempo de processamento não devem ser comparados diretamente aos resultados numéricos publicados no estudo original.

Outra limitação é a restrição do escopo aos algoritmos LMS e NLMS. O artigo também avalia RLS e AP, que apresentam diferentes compromissos entre erro e custo computacional.

Além disso, a entrada PRBS mantida por múltiplas amostras gerou correlação significativa entre os atrasos da entrada, resultando em uma matriz R_{xx} mal condicionada. Esse efeito pode influenciar a solução de Wiener e a interpretação direta dos coeficientes FIR estimados.

5 Conclusões

Este trabalho apresentou uma replicação computacional da metodologia de identificação de um motor CC por filtros adaptativos, restringindo o escopo aos algoritmos LMS e NLMS e utilizando o filtro de Wiener como referência ótima.

Os resultados indicam que LMS e NLMS foram capazes de aproximar a dinâmica dominante da planta simulada, com MSEs próximos ao obtido pela solução de Wiener. O filtro de Wiener obteve o menor erro de teste, como esperado, enquanto o LMS apresentou o menor tempo de processamento na implementação avaliada.

A análise do passo de adaptação mostrou que o desempenho do LMS depende fortemente da escolha de μ , evidenciando o compromisso entre velocidade de convergência e oscilações em regime permanente. O NLMS demonstrou a vantagem conceitual da normalização pela energia da entrada, embora, neste caso específico, a amplitude quase constante da PRBS tenha reduzido a diferença prática em relação ao LMS.

Conclui-se que o notebook desenvolvido cumpre o objetivo de aplicar a metodologia da disciplina de Processamento Adaptativo de Sinais a um problema inspirado em um estudo de caso real. Como trabalhos futuros, recomenda-se implementar os algoritmos RLS e AP, calcular MSE também para modelos treinados com downsampling, testar diferentes configurações de PRBS e, se possível, utilizar dados experimentais reais de motor CC.

Referências

- [1] S.-D. Sim, A. Medgyesi, Z. Lendek, M. Susca, V. Mihaly, D. Pislá, C. L. Vaida, P. Dobra e A. E. Pica, “Adaptive Filters for DC Motor Identification: A Case Study,” *2024 IEEE International Conference on Automation, Quality and Testing, Robotics (AQTR)*, 2024, doi: 10.1109/AQTR61889.2024.10554182.
- [2] E. P. da Silva, *Filtragem Linear Ótima*. Material da disciplina Processamento Adaptativo de Sinais,

Programa de Pós-Graduação em Engenharia Elétrica,
Universidade Federal de Campina Grande, 2026.

- [3] E. P. da Silva, *Algoritmo LMS*. Material da disciplina Processamento Adaptativo de Sinais, Programa de Pós-Graduação em Engenharia Elétrica, Universidade Federal de Campina Grande, 2024.
- [4] E. P. da Silva, *Variantes do Algoritmo LMS*. Material da disciplina Processamento Adaptativo de Sinais,

Programa de Pós-Graduação em Engenharia Elétrica,
Universidade Federal de Campina Grande, 2024.

- [5] P. S. R. Diniz, *Adaptive Filtering: Algorithms and Practical Implementation*. 4th ed. New York, NY, USA: Springer, 2012.
- [6] A. Uncini, *Fundamentals of Adaptive Signal Processing*. New York, NY, USA: Springer, 2015.